

Attention Models: da motivação às variantes modernas

Intuição geométrica, formulação matemática e aplicações

Seu Nome

17 de agosto de 2025

Table of Contents

1 Motivação e Histórico

- ▶ **Motivação e Histórico**
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Redes Neurais Recorrentes

1 Motivação e Histórico




Figura: Redes Neurais Recorrentes ¹


- Bem adaptadas para dados sequenciais como séries temporais e texto
- Diferentes tipos de modelos: LSTM, GRU
- Diferentes arquiteturas: simples, bidirecional, encoder-decoder

¹Figura de Christopher Olah

Tipos de camadas RNN


1 Motivação e Histórico

LSTM



$$\begin{aligned}
 f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), & i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i), \\
 \tilde{C}_t &= \tanh(W_c[h_{t-1}, x_t] + b_c), & C_t &= f_t \odot C_{t-1} + i_t \odot \tilde{C}_t, \\
 o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), & h_t &= o_t \odot \tanh(C_t)
 \end{aligned}$$

GRU



$$\begin{aligned}
 z_t &= \sigma(W_z \cdot [h_{t-1}, x_t]) \\
 r_t &= \sigma(W_r \cdot [h_{t-1}, x_t]) \\
 \tilde{h}_t &= \tanh(W \cdot [r_t \odot h_{t-1}, x_t]) \\
 h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t
 \end{aligned}$$

LSTM como baseline para NMT

1 Motivação e Histórico

- Encoder LSTM lê (x_1, \dots, x_n) e produz estados h_t ; o contexto é o último estado $c = h_n$.
- Decoder LSTM gera (y_1, \dots, y_m) condicionado a c .
- **Gargalo:** toda a informação comprimida em $c = h_n$.
 - Processamento **sequencial** \Rightarrow baixa paralelização.
 - **Dependências longas** ainda são difíceis (mesmo com portas).
 - **Gargalo do contexto** (vetor único) degrada qualidade em frases longas.

Atenção aditiva [1]

1 Motivação e Histórico

$$e_{ij} = a(s_{i-1}, h_j), \quad \alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^{T_x} \exp(e_{ik})}, \quad c_i = \sum_{j=1}^{T_x} \alpha_{ij} h_j$$

- h_j : estado oculto do encoder na posição j (palavra x_j).
- s_{i-1} : estado do decoder no passo anterior (y_{i-1}).
- e_{ij} : escore de alinhamento entre h_j e s_{i-1} (via rede feedforward).
- α_{ij} : pesos normalizados (softmax) \rightarrow distribuem a atenção sobre os h_j .
- c_i : vetor de contexto dinâmico usado para prever y_i .

Intuição: O decoder calcula, em cada passo, um mapa de atenção sobre os estados do encoder, decidindo onde focar.

Integração com encoder bidirecional e decoder

1 Motivação e Histórico

- O **encoder** é uma RNN bidirecional:

$$h_j = [\vec{h}_j; \overleftarrow{h}_j]$$

Cada h_j contém contexto passado e futuro da palavra x_j .

- O vetor de contexto c_i é construído a partir desses estados bidirecionais.
- O **decoder** (RNN unidirecional) atualiza seu estado com:

$$s_i = f(s_{i-1}, y_{i-1}, c_i)$$

- Usa o estado anterior s_{i-1} - O símbolo anterior y_{i-1} - O contexto dinâmico c_i

- Assim, a cada passo, o decoder combina memória interna + contexto dinâmico para prever y_i .

Resultado: Resolve o gargalo do vetor fixo único (h_n) e permite traduções mais fiéis em frases longas.

Atenção multiplicativa [2]

1 Motivação e Histórico

Três variantes de scoring:

$$e_{ij} = v^\top \tanh(W[s_j; h_i]) \quad (\text{concat, similar ao Bahdanau})$$

$$e_{ij} = s_j^\top W h_i \quad (\text{general})$$

$$e_{ij} = s_j^\top h_i \quad (\text{dot})$$

- s_j : query \rightarrow estado oculto do decoder.
- h_i : key/value \rightarrow estado do encoder.
- **Concat**: aproxima-se da atenção aditiva de Bahdanau.
- **General**: bilinear, mais expressivo (aprende W).
- **Dot**: mais simples e rápido (nenhum parâmetro extra).

Nota: Podemos reinterpretar em termos modernos como $Q = s_j$, $K = h_i$, $V = h_i$.

Global vs Local Attention [2]

1 Motivação e Histórico




Figure 2: **Global attentional model** – at each time step t , the model infers a *variable-length* alignment weight vector a_t based on the current target state h_t and all source states \bar{h}_s . A global context vector c_t is then computed as the weighted average, according to a_t , over all the source states.

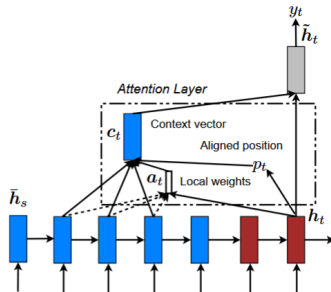


Figure 3: **Local attention model** – the model first predicts a single aligned position p_t for the current target word. A window centered around the source position p_t is then used to compute a context vector c_t , a weighted average of the source hidden states in the window. The weights a_t are inferred from the current target state h_t and those source states \bar{h}_s in the window.

Self-Attention: dependências em paralelo

1 Motivação e Histórico

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V, \quad Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

- Calcula relações *entre todos os tokens* da mesma sequência, **em paralelo**.
- Multi-head:

$$\text{MHA}(X) = \text{Concat}(H_1, \dots, H_h) W_O, \quad H_r = \text{softmax}\left(\frac{Q_r K_r^\top}{\sqrt{d_k}}\right) V_r.$$

- Comparativo: RNN/LSTM exige n passos sequenciais; self-attention faz um passo paralelo com custo $\mathcal{O}(n^2)$.

Arquitetura pré-transformer

1 Motivação e Histórico

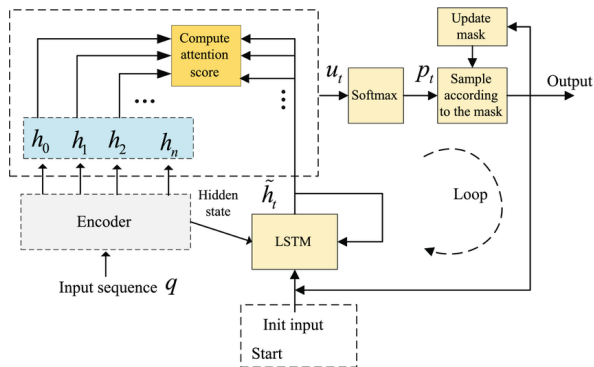


Figura: Exemplo de arquitetura pré-transformer (aditiva) [3]

Table of Contents

2 Transformers

- ▶ Motivação e Histórico
- ▶ **Transformers**
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Attention Is All You Need [4]: nascendo o Transformer

2 Transformers

- **Remove** completamente a recorrência (sem LSTM).
- **Positional encodings** preservam ordem:

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right), \quad PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right).$$




Figura: Exemplo de codificação posicional senoidal [4]

Bloco Transformer e arquitetura

2 Transformers

- Cada **bloco Transformer** (pré-norm, forma comum):

$$Y = X + \text{MHA}(\text{LN}(X)),$$

$$Z = Y + \text{FFN}(\text{LN}(Y)), \quad \text{FFN}(u) = W_2 \phi(W_1 u + b_1) + b_2,$$

- Empilha-se vários blocos de atenção+FFN \Rightarrow **arquitetura Transformer**.
- **Máscara causal** (para LMs) impede olhar o futuro:

$$\text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right), \quad M_{ij} = \begin{cases} 0, & j \leq i \\ -\infty, & j > i \end{cases}$$

Arquiteturas Transformer e Aplicações

2 Transformers

Encoder-Decoder

(Transformer original, 2017)

- Tradução automática
- Sumarização
- Diálogo
- Captioning

Encoder-only

(BERT, RoBERTa, DistilBERT)

- Classificação de texto
- NER (entidades)
- QA (extração de trechos)
- Análise semântica

Decoder-only

(GPT, LLaMA, etc.)

- Modelos de linguagem
- Geração de texto
- Completamento de prompts
- Story generation

Arquiteturas Transformer: encoder e decoder [4]

2 Transformers




Figura: Transformer Encoder e Decoder
16/68




Figura: Multi-Head Attention

Scaled Dot-Product Attention




Figura: Multi-Head Attention

Resumo da evolução dos modelos

2 Transformers

Linha do tempo (síntese):

- LSTM encoder-decoder: contexto único $c = h_n$ (gargalo).
- LSTM + **atenção** (Bahdanau/Luong): alívio do gargalo.
- **Self-attention**: dependências longas em paralelo.
- **Transformer**: atenção + posição + FFN; várias camadas empilhadas; sem LSTM.

Table of Contents

3 Roteiro

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ **Roteiro**
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico
- Modelos de sequência (RNN/LSTM) + Attention

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico
- Modelos de sequência (RNN/LSTM) + Attention
- Embeddings, interpretação geométrica e matemática

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico
- Modelos de sequência (RNN/LSTM) + Attention
- Embeddings, interpretação geométrica e matemática
- Transformers e posicionais

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico
- Modelos de sequência (RNN/LSTM) + Attention
- Embeddings, interpretação geométrica e matemática
- Transformers e posicionais
- Aplicações: Séries Temporais, Language Models, ViT, GAT

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico
- Modelos de sequência (RNN/LSTM) + Attention
- Embeddings, interpretação geométrica e matemática
- Transformers e posicionais
- Aplicações: Séries Temporais, Language Models, ViT, GAT
- Treinamento, variantes e hiperparâmetros

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico
- Modelos de sequência (RNN/LSTM) + Attention
- Embeddings, interpretação geométrica e matemática
- Transformers e posicionais
- Aplicações: Séries Temporais, Language Models, ViT, GAT
- Treinamento, variantes e hiperparâmetros
- Tamanho ideal (scaling), Mixture of Experts

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico
- Modelos de sequência (RNN/LSTM) + Attention
- Embeddings, interpretação geométrica e matemática
- Transformers e posicionais
- Aplicações: Séries Temporais, Language Models, ViT, GAT
- Treinamento, variantes e hiperparâmetros
- Tamanho ideal (scaling), Mixture of Experts
- Pruning e Distillation

Roteiro da Apresentação

3 Roteiro

- Motivação e histórico
- Modelos de sequência (RNN/LSTM) + Attention
- Embeddings, interpretação geométrica e matemática
- Transformers e posicionais
- Aplicações: Séries Temporais, Language Models, ViT, GAT
- Treinamento, variantes e hiperparâmetros
- Tamanho ideal (scaling), Mixture of Experts
- Pruning e Distillation
- Limitações, diagnóstico e conclusões

Motivação & Histórico

3 Roteiro

Table of Contents

4 Motivação

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ **Motivação**
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Por que Atenção?

4 Motivação

- Capturar dependências longas e filtrar informação relevante

Por que Atenção?

4 Motivação

- Capturar dependências longas e filtrar informação relevante
- RNNs sofrem com gradientes e paralelização limitada

Por que Atenção?

4 Motivação

- Capturar dependências longas e filtrar informação relevante
- RNNs sofrem com gradientes e paralelização limitada
- Pesos de atenção ajudam na interpretabilidade

Por que Atenção?

4 Motivação

- Capturar dependências longas e filtrar informação relevante
- RNNs sofrem com gradientes e paralelização limitada
- Pesos de atenção ajudam na interpretabilidade
- Melhor relação capacidade/compute em diversas tarefas

Histórico em 3 passos

4 Motivação

- **Additive Attention** (Bahdanau) para NMT

Histórico em 3 passos

4 Motivação

- **Additive Attention** (Bahdanau) para NMT
- **Dot-Product Attention** (Luong) — caminho para escalabilidade

Histórico em 3 passos

4 Motivação

- **Additive Attention** (Bahdanau) para NMT
- **Dot-Product Attention** (Luong) — caminho para escalabilidade
- **Transformers** (Vaswani et al., 2017): “Attention is All You Need”

Fundamentos

4 Motivação

Table of Contents

5 Modelos de Sequência

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ **Modelos de Sequência**
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

RNN/GRU/LSTM — limites práticos

5 Modelos de Sequência

- Cálculo sequencial \Rightarrow baixa paralelização

RNN/GRU/LSTM — limites práticos

5 Modelos de Sequência

- Cálculo sequencial \Rightarrow baixa paralelização
- Dependências longas: vanish/explode (mitigado, não resolvido)

RNN/GRU/LSTM — limites práticos

5 Modelos de Sequência

- Cálculo sequencial \Rightarrow baixa paralelização
- Dependências longas: vanish/explode (mitigado, não resolvido)
- Memória finita e custo de treino elevado para contextos longos

LSTM + Attention (Encoder-Decoder)

Atenção aditiva (Bahdanau)

Equações

$$e_{ij} = v^{\top} \tanh(W_1 h_i + W_2 s_j), \quad \alpha_{ij} = \text{softmax}_i(e_{ij}), \quad c_j = \sum_i \alpha_{ij} h_i$$

- **Alinhamento** dinâmico entre estados do encoder e passos do decoder

LSTM + Attention (Encoder-Decoder)

Atenção aditiva (Bahdanau)

Equações

$$e_{ij} = v^{\top} \tanh(W_1 h_i + W_2 s_j), \quad \alpha_{ij} = \text{softmax}_i(e_{ij}), \quad c_j = \sum_i \alpha_{ij} h_i$$

- **Alinhamento** dinâmico entre estados do encoder e passos do decoder
- Reduz gargalos de um único vetor de contexto

Table of Contents

6 Embeddings & Interpretações

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ **Embeddings & Interpretações**
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites
- ▶ Conclusões

Word/Subword Embeddings

6 Embeddings & Interpretações

- Estáticos (Word2Vec, GloVe) vs. Contextuais (ELMo, BERT)

Word/Subword Embeddings

6 Embeddings & Interpretações

- Estáticos (Word2Vec, GloVe) vs. Contextuais (ELMo, BERT)
- Subword (BPE/Unigram) para robustez morfológica

Word/Subword Embeddings

6 Embeddings & Interpretações

- Estáticos (Word2Vec, GloVe) vs. Contextuais (ELMo, BERT)
- Subword (BPE/Unigram) para robustez morfológica
- Análogos em outras modalidades: patches (ViT), time2vec (TS), node2vec (grafos)

Interpretação Geométrica da Atenção

6 Embeddings & Interpretações

- Q, K, V são projeções lineares do latente

Interpretação Geométrica da Atenção

6 Embeddings & Interpretações

- Q, K, V são projeções lineares do latente
- Similaridade (coseno/dot) guia uma *combinação convexa* de V

Interpretação Geométrica da Atenção

6 Embeddings & Interpretações

- Q, K, V são projeções lineares do latente
- Similaridade (coseno/dot) guia uma *combinação convexa* de V
- Multi-head \Rightarrow múltiplas métricas/projeções simultâneas

Interpretação Matemática: Self-Attention

6 Embeddings & Interpretações

Fórmula central (scaled dot-product)

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right) V$$

- Máscara causal/atencional conforme a tarefa

Interpretação Matemática: Self-Attention

6 Embeddings & Interpretações

Fórmula central (scaled dot-product)

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right) V$$

- Máscara causal/atencional conforme a tarefa
- Complexidade $\mathcal{O}(n^2)$ em tempo/memória

Interpretação Matemática: Self-Attention

6 Embeddings & Interpretações

Fórmula central (scaled dot-product)

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right) V$$

- Máscara causal/atencional conforme a tarefa
- Complexidade $\mathcal{O}(n^2)$ em tempo/memória
- Gradientes e saturação da softmax

Positional Encodings

6 Embeddings & Interpretações

- Absolutos senoidais vs. aprendidos

Positional Encodings

6 Embeddings & Interpretações

- Absolutos senoidais vs. aprendidos
- Relativos e RoPE (rotary): melhor generalização/composição

Positional Encodings

6 Embeddings & Interpretações

- Absolutos senoidais vs. aprendidos
- Relativos e RoPE (rotary): melhor generalização/composição
- Impacto em extrapolação e contextos longos

Transformers

6 Embeddings & Interpretações

Table of Contents

7 Arquiteturas & Variantes

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ **Arquiteturas & Variantes**
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites
- ▶ Conclusões

Arquiteturas Transformer

7 Arquiteturas & Variantes

- **Encoder-Decoder, Encoder-only, Decoder-only**

Arquiteturas Transformer

7 Arquiteturas & Variantes

- **Encoder-Decoder, Encoder-only, Decoder-only**
- Bloco: MHSA + FFN, *residual* + *layer norm*

Arquiteturas Transformer

7 Arquiteturas & Variantes

- **Encoder-Decoder, Encoder-only, Decoder-only**
- Bloco: MHSA + FFN, *residual* + *layer norm*
- Pré-norm vs. pós-norm (estabilidade de treino)

Atenções Eficientes

7 Arquiteturas & Variantes

- **Esparsidade:** Longformer/BigBird (padrões locais+globais)

Trade-off

Complexidade $\mathcal{O}(n^2) \rightarrow \tilde{\mathcal{O}}(n)$ com perda controlada de exatidão e/ou restrições de padrão.

Atenções Eficientes

7 Arquiteturas & Variantes

- **Esparsidade:** Longformer/BigBird (padrões locais+globais)
- **Aproximação:** Linformer, Nyströmformer

Trade-off

Complexidade $\mathcal{O}(n^2) \rightarrow \tilde{\mathcal{O}}(n)$ com perda controlada de exatidão e/ou restrições de padrão.

Atenções Eficientes

7 Arquiteturas & Variantes

- **Esparsidade:** Longformer/BigBird (padrões locais+globais)
- **Aproximação:** Linformer, Nyströmformer
- **Kernels:** Performer (favor+), FlashAttention (IO-aware)

Trade-off

Complexidade $\mathcal{O}(n^2) \rightarrow \tilde{\mathcal{O}}(n)$ com perda controlada de exatidão e/ou restrições de padrão.

Atenções Eficientes

7 Arquiteturas & Variantes

- **Esparsidade:** Longformer/BigBird (padrões locais+globais)
- **Aproximação:** Linformer, Nyströmformer
- **Kernels:** Performer (favor+), FlashAttention (IO-aware)
- **Outros:** Reformer (LSH)

Trade-off

Complexidade $\mathcal{O}(n^2) \rightarrow \tilde{\mathcal{O}}(n)$ com perda controlada de exatidão e/ou restrições de padrão.

Table of Contents

8 Treino & Hiperparâmetros

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ **Treino & Hiperparâmetros**
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Práticas de Treino

8 Treino & Hiperparâmetros

- AdamW, warmup + decaimento; label smoothing quando aplicável

Práticas de Treino

8 Treino & Hiperparâmetros

- AdamW, warmup + decaimento; label smoothing quando aplicável
- Regularização: dropout, stochastic depth, weight decay

Práticas de Treino

8 Treino & Hiperparâmetros

- AdamW, warmup + decaimento; label smoothing quando aplicável
- Regularização: dropout, stochastic depth, weight decay
- AMP/mixed precision, grad clipping, checkpointing

Práticas de Treino

8 Treino & Hiperparâmetros

- AdamW, warmup + decaimento; label smoothing quando aplicável
- Regularização: dropout, stochastic depth, weight decay
- AMP/mixed precision, grad clipping, checkpointing
- Dados: curriculum, masking, augmentation (TS/ViT/GAT)

Hiperparâmetros Essenciais

8 Treino & Hiperparâmetros

- Profundidade, d_{model} , #heads, d_{ff} , dropout

Hiperparâmetros Essenciais

8 Treino & Hiperparâmetros

- Profundidade, d_{model} , #heads, d_{ff} , dropout
- Comprimento de contexto, batch size, *LR schedule*

Hiperparâmetros Essenciais

8 Treino & Hiperparâmetros

- Profundidade, d_{model} , #heads, d_{ff} , dropout
- Comprimento de contexto, batch size, *LR schedule*
- Específicos: tokenização (LM), *patch size* (ViT), janela/patch (TS)

Qual tamanho ideal? (Scaling)

8 Treino & Hiperparâmetros

- Leis de escala vs. limite de dados/compute

Qual tamanho ideal? (Scaling)

8 Treino & Hiperparâmetros

- Leis de escala vs. limite de dados/compute
- Tokens vs. parâmetros; saturação com contexto

Qual tamanho ideal? (Scaling)

8 Treino & Hiperparâmetros

- Leis de escala vs. limite de dados/compute
- Tokens vs. parâmetros; saturação com contexto
- Regra prática: dimensione para o dataset e o *budget* de inferência

Aplicações

8 Treino & Hiperparâmetros

Table of Contents

9 Séries Temporais

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ **Séries Temporais**
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites
- ▶ Conclusões

Atenção em Séries Temporais

9 Séries Temporais

- Codificação temporal: absolutos/relativos, time2vec, calendários/sazonalidade

Atenção em Séries Temporais

9 Séries Temporais

- Codificação temporal: absolutos/relativos, time2vec, calendários/sazonalidade
- Exógenas e *cross-attention*; *patching* para contextos longos

Atenção em Séries Temporais

9 Séries Temporais

- Codificação temporal: absolutos/relativos, time2vec, calendários/sazonalidade
- Exógenas e *cross-attention*; *patching* para contextos longos
- Tarefas: previsão, imputação, detecção de anomalias

Table of Contents

10 Language Models

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ **Language Models**
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites
- ▶ Conclusões

Language Models (LM)

10 Language Models

- Atenção **causal**, *next-token* e *masking*

Language Models (LM)

10 Language Models

- Atenção **causal**, *next-token* e *masking*
- Pré-treino vs. *fine-tuning*; Instrução/LoRA/Adapters

Language Models (LM)

10 Language Models

- Atenção **causal**, *next-token* e *masking*
- Pré-treino vs. *fine-tuning*; Instrução/LoRA/Adapters
- Métricas: perplexidade e tarefas *downstream*

Table of Contents

11 Vision Transformer

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ **Vision Transformer**
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Vision Transformer (ViT)

11 Vision Transformer

- Imagem \rightarrow *patches* + [CLS] token

Vision Transformer (ViT)

11 Vision Transformer

- Imagem \rightarrow *patches* + [CLS] token
- Posicionais 2D; augmentations (RandAug, Mixup/CutMix)

Vision Transformer (ViT)

11 Vision Transformer

- Imagem \rightarrow *patches* + [CLS] token
- Posicionais 2D; augmentations (RandAug, Mixup/CutMix)
- Transfer: *linear probe* vs. *fine-tune*

Table of Contents

12 Graph Attention

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ **Graph Attention**
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites
- ▶ Conclusões

Graph Attention Networks (GAT)

12 Graph Attention

Coeficientes de Atenção (um cabeçalho)

$$\alpha_{ij} = \text{softmax}_j(\text{LeakyReLU}(a^\top [Wh_i || Wh_j]))$$

- Multi-head; sobre-*smoothing* e escalabilidade

Graph Attention Networks (GAT)

12 Graph Attention

Coeficientes de Atenção (um cabeçalho)

$$\alpha_{ij} = \text{softmax}_j(\text{LeakyReLU}(a^\top [Wh_i || Wh_j]))$$

- Multi-head; sobre-*smoothing* e escalabilidade
- Heterógrafos e atenção relacional

Escala & Compressão

12 Graph Attention

Table of Contents

13 MoE, Pruning, Distillation

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ **MoE, Pruning, Distillation**
- ▶ Diagnóstico & Limites

Mixture of Experts (MoE)

13 MoE, Pruning, Distillation

- *Gating* top-1/top-2; balanceamento de carga

Mixture of Experts (MoE)

13 MoE, Pruning, Distillation

- *Gating* top-1/top-2; balanceamento de carga
- Roteamento esparsos: capacidade vs. ociosidade

Mixture of Experts (MoE)

13 MoE, Pruning, Distillation

- *Gating* top-1/top-2; balanceamento de carga
- Roteamento esparso: capacidade vs. ociosidade
- Custos de comunicação e estabilidade no treino

Pruning

13 MoE, Pruning, Distillation

- Não estruturado (magnitude) vs. estruturado (canal/bloco, n:m)

Pruning

13 MoE, Pruning, Distillation

- Não estruturado (magnitude) vs. estruturado (canal/bloco, $n:m$)
- Iterativo vs. *one-shot*; impacto em latência real

Pruning

13 MoE, Pruning, Distillation

- Não estruturado (magnitude) vs. estruturado (canal/bloco, n:m)
- Iterativo vs. *one-shot*; impacto em latência real
- Interação com quantização e *sparsity-aware kernels*

Distillation

13 MoE, Pruning, Distillation

Perda típica (Hinton)

$$\mathcal{L} = (1 - \lambda) \text{CE}(y, s) + \lambda T^2 \text{KL}(p_T \parallel q_T)$$

- *Teacher* \rightarrow *student*; temperatura T

Distillation

13 MoE, Pruning, Distillation

Perda típica (Hinton)

$$\mathcal{L} = (1 - \lambda) \text{CE}(y, s) + \lambda T^2 \text{KL}(p_T \parallel q_T)$$

- *Teacher* \rightarrow *student*; temperatura T
- *Intermediate layer hints*; *task-specific* vs. *generalista*

Distillation

13 MoE, Pruning, Distillation

Perda típica (Hinton)

$$\mathcal{L} = (1 - \lambda) \text{CE}(y, s) + \lambda T^2 \text{KL}(p_T \parallel q_T)$$

- *Teacher* \rightarrow *student*; temperatura T
- *Intermediate layer hints*; *task-specific* vs. *generalista*
- Benefícios: latência/energia e *edge deployment*

Interpretação & Limitações

13 MoE, Pruning, Distillation

Table of Contents

14 Diagnóstico & Limites

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ **Diagnóstico & Limites**

Interpretação & Diagnóstico

14 Diagnóstico & Limites

- *Attention rollout/flow; atenção \neq causalidade*

Interpretação & Diagnóstico

14 Diagnóstico & Limites

- *Attention rollout/flow*; atenção \neq causalidade
- *Probing* de camadas; ablação de cabeças

Interpretação & Diagnóstico

14 Diagnóstico & Limites

- *Attention rollout/flow*; atenção \neq causalidade
- *Probing* de camadas; ablação de cabeças
- Ferramentas de *explainability* por domínio

Limitações & Trade-offs

14 Diagnóstico & Limites

- Custo $\mathcal{O}(n^2)$, viés de dados, OOD robustness

Limitações & Trade-offs

14 Diagnóstico & Limites

- Custo $\mathcal{O}(n^2)$, viés de dados, OOD robustness
- Contaminação de treino e privacidade

Limitações & Trade-offs

14 Diagnóstico & Limites

- Custo $\mathcal{O}(n^2)$, viés de dados, OOD robustness
- Contaminação de treino e privacidade
- Energia/carbono e restrições de hardware

Table of Contents

15 Conclusões

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Conclusões

15 Conclusões

- Atenção como princípio unificador em sequência, visão e grafos

Conclusões

15 Conclusões

- Atenção como princípio unificador em sequência, visão e grafos
- Escolha guiada por dados, métricas e orçamento (treino/inferência)

Conclusões

15 Conclusões

- Atenção como princípio unificador em sequência, visão e grafos
- Escolha guiada por dados, métricas e orçamento (treino/inferência)
- Escala e compressão (MoE/pruning/distillation) para produção

Attention Models: da motivação às variantes modernas

Obrigado pela Atenção!

Alguma Pergunta?

Natanael Moura Junior

natmourajr@poli.ufrj.br, natmourajr@lps.ufrj.br

Perguntas?

15 Conclusões

Obrigado!

Table of Contents

16 Backup (Opcional)

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Equações úteis (resumo)

16 Backup (Opcional)

- Scaled dot-product, aditiva (Bahdanau)
- Atenção relativa e RoPE
- GAT detalhado; máscaras causais

Hiperparâmetros por tarefa (resumo)

16 Backup (Opcional)

- LM: contexto, BPE, heads/profundidade típicos
- ViT: patch size, MLP ratio, augmentations
- TS: janela, patching, covariáveis, perdas (MAE/MSE/Quantile)

Table of Contents

17 Referências Bibliográficas

- ▶ Motivação e Histórico
- ▶ Transformers
- ▶ Roteiro
- ▶ Motivação
- ▶ Modelos de Sequência
- ▶ Embeddings & Interpretações
- ▶ Arquiteturas & Variantes
- ▶ Treino & Hiperparâmetros
- ▶ Séries Temporais
- ▶ Language Models
- ▶ Vision Transformer
- ▶ Graph Attention
- ▶ MoE, Pruning, Distillation
- ▶ Diagnóstico & Limites

Referências Bibliográficas

17 Referências Bibliográficas

- [1] D. Bahdanau, K. Cho, and Y. Bengio, “Neural machine translation by jointly learning to align and translate,” *arXiv preprint arXiv:1409.0473*, 2014.
- [2] M.-T. Luong, H. Pham, and C. D. Manning, “Effective approaches to attention-based neural machine translation,” in *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 1412–1421, 2015.
- [3] S. Gu and Y. Zhuang, “Method for solving constrained 0-1 quadratic programming problems based on pointer network and reinforcement learning,” *Neural Computing and Applications*, vol. 35, 2022.

Referências Bibliográficas

17 Referências Bibliográficas

- [4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.